

Predykcja Cen Biletów Lotniczych

Analiza i Modelowanie

Projekt z przedmiotu: **Eksploracja Danych**

Autor: Jakub Szamik

2025

Zbiór danych: *Flight Price Prediction* (Kaggle)
<https://www.kaggle.com/datasets/shubhambathwal/flight-price-prediction>

Spis treści

Streszczenie	3
1 Wybór Zbioru Danych	3
2 Definicja Problemu i Charakterystyka Zbioru	3
2.1 Problem predykcyjny	3
2.2 Zmienne w zbiorze	4
2.3 Podstawowe statystyki	4
3 Przegląd Literatury	4
4 Czyszczenie Danych i Selekcja Cech	5
4.1 Wstępna obróbka i kodowanie	5
4.2 Usunięcie wartości ekstremalnych	5
4.3 Wykrywanie anomalii — Isolation Forest	5
4.4 Warianty zbioru danych	5
4.5 Wstępna selekcja cech	6
5 Eksploracja Danych (EDA)	6
5.1 Rozkład zmiennej docelowej	6
5.2 Macierz korelacji	6
5.3 Rozkład zmiennych kategoriycznych	7
5.4 Analiza linii lotniczych i klas podróży	7
5.5 Zależność ceny od czasu do wylotu i czasu lotu	8
6 Przygotowanie Danych do Modelowania	8
7 Model Łączny — Punkt Wyjścia	9
7.1 Dlaczego model łączny jest niewystarczający	9
7.2 Wybór optymalnego wariantu danych	9
7.3 Porównywane algorytmy	9
7.4 Wyniki modelu łącznego	9
7.5 Dominacja zmiennej <code>is_business</code> — ukryty problem modelu łącznego . .	10
7.6 Diagnostyka przetrenowania — Random Forest	11
8 Modele Segmentowe — Economy vs. Business	11
8.1 Uzasadnienie podziału na segmenty	11
8.2 Macierze korelacji dla każdego segmentu	11
8.3 Wyniki modeli segmentowych	13
8.4 Ważność cech w modelach segmentowych	13
8.5 Diagnostyka przetrenowania — wszystkie modele, oba segmenty	14
9 Ewaluacja i Kalibracja Modeli Segmentowych	15
9.1 Krzyżowa walidacja (5-krotna CV)	15
9.2 Tuning hiperparametrów — LightGBM	15
9.3 Krzywe uczenia	16
10 Analiza Błędów	17

10.1 Rozkład residuów — LightGBM	17
10.2 Najtrudniejsze przypadki — efekt last-minute	18
10.3 Porównanie rozkładów błędów — wszystkie modele	19
11 Wyjaśnialność Modeli (XAI) — SHAP	19
11.1 Globalny wpływ cech — Summary Plot	20
11.2 Efekt last-minute — Dependence Plot	21
12 Wdrożenie Modelu i Test Predykcyjny	22
12.1 Test predykcyjny i wnioski	22
13 Podsumowanie i Wnioski	24
13.1 Model łączny vs. modele segmentowe	24
13.2 Wybór algorytmu — LightGBM jako model finalny	24
13.3 Kluczowe predyktory	24
13.4 Możliwe kierunki dalszych badań	24

Streszczenie

Projekt dotyczy predykcji cen biletów lotniczych na podstawie zbioru *Flight Price Prediction* (Kaggle) zawierającego ponad 300 000 rekordów z tras krajowych w Indiach. Cel: zbudowanie modelu regresyjnego o możliwie najwyższej dokładności predykcji ceny biletu (w INR).

Zastosowano podejście wieloetapowe: eksploracja danych (EDA), wykrywanie anomalii metodą **Isolation Forest**, porównanie sześciu algorytmów uczenia maszynowego (LinearRegression, Ridge, Random Forest, Gradient Boosting, XGBoost, LightGBM), ewaluacja z krzyżową walidacją i tuningiem hiperparametrów. Jako modele finalne wybrano **LightGBM** — osobno dla klasy Economy i Business. Wyjaśnialność decyzji modeli przeanalizowano metodą **SHAP**.

1. Wybór Zbioru Danych

Analizowany zbiór danych pochodzi z portalu Kaggle i nosi nazwę *Flight Price Prediction (Clean_Dataset.csv)*. Zawiera informacje o cenach biletów lotniczych na trasach krajowych w Indiach, zebrane dla sześciu głównych linii lotniczych obsługujących sześć miast. Zbiór liczy **ponad 300 000 rekordów** i jest gotowy do użycia — nie zawiera brakujących wartości.

Zbiór wyróżnia się ze względu na:

- dużą liczebność umożliwiającą wiarygodną ewaluację modeli,
- naturalny podział na dwa segmenty cenowe (Economy / Business),
- obecność silnych zależności nieliniowych (efekt *last-minute*),
- dostępność zarówno zmiennych numerycznych, jak i kategorycznych.

Źródło: <https://www.kaggle.com/datasets/shubhambathwal/flight-price-prediction>

2. Definicja Problemu i Charakterystyka Zbioru

2.1 Problem predykcyjny

Celem jest zbudowanie modelu **regresji nadzorowanej** prognozującego cenę biletu lotniczego (zmienna *price*, w INR) na podstawie dostępnych cech opisujących rejs. Zmienna docelowa jest ciągła — zadanie klasyfikowane jako regresja.

2.2 Zmienne w zbiorze

Zmienna	Kodowanie	Opis	Typ
airline	One-Hot	Linia lotnicza (6 kategorii)	kategoryczna
source_city	One-Hot	Miasto wylotu (6 miast)	kategoryczna
destination_city	One-Hot	Miasto przylotu (6 miast)	kategoryczna
departure_time	One-Hot	Pora dnia odlotu (6 pasm)	kategoryczna
arrival_time	One-Hot	Pora dnia przylotu (6 pasm)	kategoryczna
stops	numerycznie	Liczba przesiadek: 0, 1, 2+	porządkowa
duration	—	Czas trwania lotu (godz.)	numeryczna
days_left	—	Liczba dni do wylotu	numeryczna
class	0/1	Klasa podróży (Economy=0, Business=1)	binarna
price	—	Cena biletu w INR (cel)	numeryczna

Tabela 1: Zmienne w zbiorze danych wraz ze strategią kodowania

2.3 Podstawowe statystyki

Zmienna docelowa **price** charakteryzuje się znaczną asymetrią prawostronną — mediana wyraźnie odbiega od średniej, co sugeruje obecność obserwacji odstających po prawej stronie rozkładu. Ceny biletów klasy Business są wielokrotnie wyższe niż Economy, co uzasadnia późniejsze modelowanie osobne dla każdej klasy.

3. Przegląd Literatury

Predykcja cen biletów lotniczych jest aktywnie badanym problemem w literaturze uczenia maszynowego. Poniżej zebrano kluczowe prace stanowiące punkt odniesienia dla niniejszej analizy.

- **Groves & Gini (2011)** — jedno z pierwszych zastosowań ML (regresja liniowa, SVM) do prognozowania cen lotów. Autorzy wskazują na silną nieliniowość zależności cena–czas do wylotu.
- **Janssen et al. (2015)** — analiza dynamicznego ustalania cen (*dynamic pricing*) linii lotniczych; potwierdzono, że ceny rosną wykładniczo w ostatnich tygodniach przed wylotem.
- **Tziridis et al. (2017)** — porównanie modeli (regresja liniowa, Random Forest, sieci neuronowe) na danych greckich linii lotniczych; Random Forest uzyskał najniższy MAE.
- **Liu et al. (2008)** — **Isolation Forest** — metoda detekcji anomalii zastosowana w niniejszym projekcie. Algorytm izoluje obserwacje odstające przez losowe partycjonowanie przestrzeni cech.
- **Chen & Guestrin (2016)** — **XGBoost** oraz **Ke et al. (2017)** — **LightGBM** — wiodące algorytmy gradientowego boostingu osiągające wysokie wyniki w zadaniach regresji na danych tabelarycznych.
- **Lundberg & Lee (2017)** — **SHAP** — metoda wyjaśnialności modeli ML oparta na teorii gier Shapleya, zastosowana w sekcji 11 do interpretacji decyzji modeli drzewiastych.

Wnioski z literatury: modele zespołowe (Random Forest, XGBoost, LightGBM) konsekwentnie przewyższają modele liniowe w zadaniach regresji cen lotniczych. Kluczowymi predyktorami są: `days_left`, `duration` oraz klasa podróży.

4. Czyszczenie Danych i Selekcja Cech

4.1 Wstępna obróbka i kodowanie

Dane wczytano bez konieczności obsługi brakujących wartości (`isnull().any()` zwraca `False`). Wykonano następujące przekształcenia wstępne:

- usunięto kolumnę `Unnamed: 0` (indeks artefaktowy z CSV),
- `stops`: zmapowano `zero`→0, `one`→1, `two_or_more`→2,
- `class`: zmapowano `Economy`→0, `Business`→1 (kolumna `is_business`),
- `departure_time`: zmapowano na skalę porządkową 1–6 (`Early Morning`→1, ..., `Late Night`→6).


4.2 Usunięcie wartości ekstremalnych

Na podstawie rozkładu zmiennej `price` usunięto obserwacje z ceną powyżej **75 000 INR** jako wartości skrajnie niereprezentatywne dla typowego rynku. Odsetek usuniętych rekordów wyniósł poniżej 1% całego zbioru. Wynik oczyszczony zapisano jako `df_clean`.

4.3 Wykrywanie anomalii — Isolation Forest

Metoda Isolation Forest (Liu et al., 2008) identyfikuje anomalie przez losowe partycjonowanie przestrzeni cech i pomiar liczby podziałów potrzebnych do izolacji obserwacji. Obserwacje wymagające mniejszej liczby podziałów uznawane są za anomalie.

Przetestowano dwa poziomy parametru `contamination`: **0,01** (1% odrzuconych) oraz **0,05** (5% odrzuconych). Do detekcji użyto zmiennych: `price`, `duration`, `days_left`.



Rysunek 1: Detekcja anomalii metodą Isolation Forest (`contamination = 0,01` i `0,05`)

4.4 Warianty zbioru danych

Na potrzeby porównania wpływu usunięcia anomalii wydzielono trzy wersje:

Zbiór	Opis	Contamination
df1	Pełny df_clean, anomalie nieusunięte	—
df2	Anomalie usunięte (1% obserwacji odrzuconych)	0,01
df3	Anomalie usunięte (5% obserwacji odrzuconych)	0,05

Tabela 2: Trzy warianty zbioru danych


4.5 Wstępna selekcja cech

Usunięto kolumnę `flight` (identyfikator lotu bez wartości predykcyjnej). Zmienne kategoryczne (`airline`, `source_city`, `destination_city`, `departure_time`, `arrival_time`) zakodowano metodą **One-Hot Encoding** z parametrem `drop_first=True` w celu uniknięcia wieloliniowości.

5. Eksploracja Danych (EDA)

5.1 Rozkład zmiennej docelowej


Rozkład ceny biletu po odcięciu obserwacji powyżej 75 000 INR wykazuje wyraźną prawostronność — większość biletów koncentruje się w niskim przedziale cenowym, przy nielicznych obserwacjach o wysokich wartościach. Widoczny jest bimodalny charakter rozkładu wynikający z podziału na klasę Economy i Business.

Rysunek 2: Rozkład zmiennej docelowej `price` — boxplot i histogram z KDE

5.2 Macierz korelacji

Macierz korelacji Pearsona dla zmiennych numerycznych wskazuje na:


- silną korelację `is_business` z `price` — odzwierciedla fundamentalną różnicę cenową między klasami,
- umiarkowaną korelację `duration` z `price` — dłuższe trasy są droższe,
- słabą, ale widoczną korelację `days_left` z `price` — ceny rosną wraz ze zbliżaniem się terminu wylotu.



Rysunek 3: Macierz korelacji Pearsona dla zmiennych numerycznych (df_clean)

5.3 Rozkład zmiennych kategorycznych


Analiza rozkładu zmiennych kategorycznych (linia lotnicza, miasto wylotu/przylotu, pora odlotu) z obliczeniem współczynnika zmienności CV. Wartość $CV < 0,3$ wskazuje na względnie równomierny rozkład — dane są dobrze zbalansowane dla większości zmiennych kategorycznych.



Rysunek 4: Rozkład obserwacji według linii lotniczej, miast i pory odlotu

5.4 Analiza linii lotniczych i klas podróży


Zestawienie liczby lotów z podziałem na klasę Economy/Business oraz rozkłady cen dla poszczególnych linii. Widoczne jest silne zróżnicowanie cenowe między przewoźnikami oraz dominacja biletów klasy Economy w zbiorze.




Rysunek 5: Liczba lotów i rozkład cen według linii lotniczej i klasy podróży

5.5 Zależność ceny od czasu do wylotu i czasu lotu

Analiza dotyczy wyłącznie lotów bez przesiadek (`stops=0`), aby wyeliminować wpływ zmiennej `stops` na czas trwania. Wykresy rozrzutu z nałożoną linią trendu (średnia grupowa) potwierdzają nieliniową zależność ceny od `days_left` — ceny rosną wykładniczo wraz ze zbliżaniem się terminu wylotu, co jest zgodne z modelem *dynamic pricing* (Jansen et al., 2015).



Rysunek 6: Zależność ceny od `days_left`, `duration` i pory odlotu — Economy (loty non-stop)



Rysunek 7: Zależność ceny od `days_left`, `duration` i pory odlotu — Business (loty non-stop)

6. Przygotowanie Danych do Modelowania

Przed właściwym modelowaniem wykonano ostateczne przekształcenia danych:

1. **Wybór optymalnego wariantu zbioru** — na podstawie porównania modelu bazowego (patrz sekcja 7) wybrano `df3`.
2. **One-Hot Encoding** zmiennych kategorycznych z `drop_first=True`.
3. **Podział 80% trening / 20% test**, `random_state=42`.

4. **Skalowanie** (`StandardScaler`) — wyłącznie dla modeli liniowych (Ridge) w ramach Pipeline.
5. **Podział według klasy** — osobne zbiory `df_economy` i `df_business` dla modelowania segmentowego (sekcja 8).

7. Model Łączny — Punkt Wyjścia

7.1 Dlaczego model łączny jest niewystarczający

Pierwszym krokiem było wytrenowanie wszystkich sześciu algorytmów na **jednym wspólnym zbiorze** obejmującym zarówno bilety Economy, jak i Business (`df3`). Podejście to stanowi naturalny punkt wyjścia — pozwala ocenić, jak modele radzą sobie z danymi o fundamentalnie różnych rozkładach cen w ramach jednej struktury.

Kluczowy problem z modelem łącznym wynika wprost z EDA: ceny biletów Business są **kilkukrotnie wyższe** niż Economy, a zależności cenowe (np. wrażliwość na `days_left`) mają inną charakterystykę w każdym segmencie. Pojedynczy model musi więc kompromisowo aproksymować dwa różne rozkłady jednocześnie, co nieuchronnie obniża jakość predykcji w obu klasach.

7.2 Wybór optymalnego wariantu danych

W celu wyznaczenia najlepszego wariantu danych wejściowych porównano trzy zbiory (`df1`, `df2`, `df3`) za pomocą modelu bazowego — regresji liniowej. Dla każdego wariantu wykonano te same kroki: usunięto kolumny pomocnicze (indeks artefaktowy i etykiety anomalii), wyodrębniono zmienną docelową `price`, zakodowano zmienne katgoryczne metodą One-Hot Encoding, podzielono dane na zbiór treningowy i testowy (80/20), a następnie wytrenowano model regresji liniowej i obliczono metryki R^2 , MAE i RMSE na zbiorze testowym. Zbiór `df3` (`contamination = 0,05`) uzyskał najwyższe R^2 i najniższe MAE/RMSE — wszystkie dalsze eksperymenty prowadzone są na `df3`.

7.3 Porównywane algorytmy

Model	Opis i parametry
LinearRegression	Klasyczna regresja MNK — punkt odniesienia (baseline)
Ridge	Regresja L2, $\alpha = 1$, skalowanie <code>StandardScaler</code> w Pipeline
Random Forest	100 drzew, <code>random_state=42</code> , <code>n_jobs=-1</code>
Gradient Boosting	100 estymatorów, <code>random_state=42</code> (sklearn)
XGBoost	300 estymatorów, <code>learning_rate=0.05</code>
LightGBM	300 estymatorów, <code>learning_rate=0.05</code>

Tabela 3: Porównywane algorytmy regresji z parametrami

7.4 Wyniki modelu łącznego

Poniższy wykres przedstawia zestawienie metryk (MAE, RMSE, R^2) dla wszystkich sześciu algorytmów trenowanych na połączonym zbiorze `df3`. Widoczna jest wyraźna hierarchia: modele liniowe wypadają najgorzej, modele drzewiaste lepiej, przy czym LightGBM dominuje pod względem R^2 .




Rysunek 8: Zestawienie wyników wszystkich modeli na zbiorze df3 (model łączny Economy + Business)

Wyniki modelu łącznego są zadowalające na poziomie ogólnym, ale ukrywają istotną słabość: model jednocześnie stara się dopasować do dwóch populacji o zupełnie innych rozkładach cen. To właśnie uzasadnia przejście do podejścia segmentowego.

7.5 Dominacja zmiennej `is_business` — ukryty problem modelu łącznego

Wykres ważności cech modelu LightGBM trenowanego na połączonym zbiorze ujawnia fundamentalny problem podejścia łącznego. Zastosowana metryka *gain* — mierząca łączną redukcję błędu przypadającą na daną cechę — jednoznacznie wskazuje, że zmienna `is_business` dominuje nad pozostałymi predyktorami. Wynika to z faktu, że pojedynczy podział po tej zmiennej eliminuje ogromną część błędu: ceny klasy Business są wielokrotnie wyższe niż Economy, więc jeden split na korzeniu drzewa redukuje MSE o dziesiątki tysięcy INR. Model łączny zamiast uczyć się złożonych zależności cenowych, skupia się głównie na **odróżnianiu klasy Economy od Business**.



Rysunek 9: Ważność cech LightGBM (*gain*) — model łączny. `is_business` dominuje, spychając `days_left`, `duration` i pozostałe cechy do marginalnego znaczenia.

To właśnie ten efekt uzasadnia przejście do modeli segmentowych — po rozbiciu zbioru na Economy i Business każdy model może skupić się na rzeczywistych predyktorach ceny, a nie na trywialnym podziale klasowym.

7.6 Diagnostyka przetrenowania — Random Forest

Już na etapie modelu łącznego ujawnia się krytyczny problem Random Forest — silne przetrenowanie. Porównanie R^2 na zbiorze treningowym i testowym pokazuje przepaść niedopuszczalną w zastosowaniach produkcyjnych:

Model	Train R^2	Test R^2
Random Forest	$\approx 0,99$	$\approx 0,95$
LightGBM	$\approx 0,97$	$\approx 0,97$

Różnica $\text{Train } R^2 - \text{Test } R^2 > 0,05$ klasyfikuje Random Forest jako model **przetrenowany** (*overfitting*). Oznacza to, że model zapamiętał dane treningowe zamiast nauczyć się generalizowalnych wzorców. Z tego powodu zostaje odrzucony jako model finalny na rzecz **LightGBM**, który osiąga porównywalną lub wyższą dokładność bez przetrenowania i przy znacznie krótszym czasie treningu.

8. Modele Segmentowe — Economy vs. Business


8.1 Uzasadnienie podziału na segmenty

Analiza EDA jednoznacznie pokazuje, że bilety Economy i Business to dwie strukturalnie odrębne populacje. Różnią się nie tylko poziomem cen, ale też charakterem zależności — wrażliwość ceny na `days_left` jest inna w każdym segmencie, podobnie jak wpływ linii lotniczej czy liczby przesiadek.


Pojedynczy model łączny musi kompromisowo aproksymować oba segmenty jednocześnie, co ogranicza jego potencjał. Rozwiązaniem jest wytrenowanie **dwóch niezależnych modeli** — osobno dla klasy Economy i osobno dla klasy Business. Każdy model uczy się wyłącznie na danych ze swojego segmentu i nie jest “rozpraszany” przez inaczej skonstruowane ceny z drugiej klasy.

8.2 Macierze korelacji dla każdego segmentu

Osobne macierze korelacji dla klas Economy i Business potwierdzają różnice strukturalne między segmentami. W klasie Economy dominującym predyktorem jest `days_left`, podczas gdy w klasie Business rozkład korelacji jest bardziej jednorodny.




Rysunek 10: Macierz korelacji dla klasy Economy — inne proporcje zależności niż w modelu łącznym




Rysunek 11: Macierz korelacji dla klasy Business — odmienna struktura korelacji

8.3 Wyniki modeli segmentowych

Dla obu klas przetestowano ten sam zestaw sześciu algorytmów i zestawiono wyniki w postaci wykresów słupkowych metryk MAE, RMSE i R^2 . Modele segmentowe osiągają wyraźnie wyższe R^2 i niższe błędy niż odpowiadające im modele łączne — szczególnie widoczne w klasie Economy, gdzie heterogeniczność łączonego zbioru najbardziej szkodziła jakości predykcji.




Rysunek 12: MAE, RMSE i R^2 dla wszystkich modeli — klasa Economy. LightGBM dominuje przy braku przetrenowania.




Rysunek 13: MAE, RMSE i R^2 dla wszystkich modeli — klasa Business. LightGBM ponownie najlepszy.

8.4 Ważność cech w modelach segmentowych

Wykresy ważności cech (LightGBM, `importance_type='gain'`) potwierdzają, że kluczowe predyktory różnią się między segmentami — co byłoby niemożliwe do uchwycenia przez model łączny operujący na jednym zestawie wag dla całego zbioru. Metryka *gain* mierzy łączną redukcję błędu wygenerowaną przez daną cechę we wszystkich podziałach i wszystkich drzewach, co daje rzetelniejszy obraz rzeczywistej siły predyktora niż domyślna metryka *split* (liczba użyć cechy).




Rysunek 14: Top 10 cech wg ważności — Economy (LightGBM, gain). Dominuje `days_left` i `duration`.



Rysunek 15: Top 10 cech wg ważności — Business (LightGBM, gain). Wyraźniejszy wpływ cech linii lotniczej niż w klasie Economy.

8.5 Diagnostyka przetrenowania — wszystkie modele, oba segmenty

Systematyczna analiza overfittingu potwierdza wnioski z modelu łącznego: Random Forest przekracza próg $\text{Train } R^2 - \text{Test } R^2 > 0,05$ **w obu klasach**, podczas gdy LightGBM i XGBoost pozostają w normie. Diagram poniżej zbiera wszystkie modele obu klas w jednym zestawieniu.




Rysunek 16: Diagnostyka przetrenowania wszystkich modeli — Economy i Business. Random Forest oznaczony jako OVERFIT w obu klasach.

9. Ewaluacja i Kalibracja Modeli Segmentowych

9.1 Krzyżowa walidacja (5-krotna CV)

Pojedynczy podział train/test może być wrażliwy na losowy dobór próby. Przeprowadzono **5-krotną walidację krzyżową** (KFold, shuffle=True, random_state=42) dla modeli LightGBM, XGBoost i Random Forest — osobno dla klasy Economy i Business. Raportowane są średnie R^2 , MAE i RMSE wraz z odchyleniem standardowym.



Rysunek 17: Wyniki 5-krotnej walidacji krzyżowej (mean $\pm$ std). LightGBM utrzymuje przewagę przy niskiej wariancji.

9.2 Tuning hiperparametrów — LightGBM


LightGBM został wybrany do tuningu jako model osiągający najlepsze wyniki bez oznak przetrenowania. Przeprowadzono **RandomizedSearchCV** (20 iteracji, 3-krotna CV, scoring: neg_mean_absolute_error) z przestrzenią poszukiwań:

Hiperparametr	Przestrzeń poszukiwań
n_estimators	[100, 200, 300, 500]
learning_rate	[0.01, 0.05, 0.1, 0.2]
max_depth	[-1, 5, 7, 10]
num_leaves	[31, 63, 127, 255]
subsample	[0.6, 0.7, 0.8, 1.0]
colsample_bytree	[0.6, 0.7, 0.8, 1.0]
reg_alpha / lambda	[0, 0.1, 1, 10] / [1, 5, 10]


Tabela 4: Przestrzeń hiperparametrów w RandomizedSearchCV

9.3 Krzywe uczenia

Krzywe uczenia ilustrują zmianę R^2 w zależności od liczby próbek treningowych. Zbieżność krzywych treningowej i walidacyjnej w obu segmentach potwierdza brak przetrenowania — LightGBM wykazuje stabilne, przewidywalne zachowanie.



Rysunek 18: Krzywa uczenia LightGBM — Economy. Krzywe zbiegają się, brak overfittingu.




Rysunek 19: Krzywa uczenia LightGBM — Business. Analogicznie stabilne zachowanie.


10. Analiza Błędów

10.1 Rozkład residuów — LightGBM

Analiza residuów (różnica między wartością rzeczywistą a predygowaną) pozwala ocenić, czy błędy modelu mają charakter losowy (pożądany) czy systematyczny. Dla obu klas sprawdzono histogram residuów z KDE, wykres residuów vs. wartości predykowane oraz wykres rzeczywistych vs. predykowanych wartości.




Rysunek 20: Rozkład residuów LightGBM — Economy. Rozkład bliski normalnemu, brak wyraźnego trendu.




Rysunek 21: Rozkład residuów LightGBM — Business. Podobna charakterystyka, nieco większy rozrzut.

10.2 Najtrudniejsze przypadki — efekt last-minute

Zidentyfikowano 10 obserwacji z największym błędem bezwzględnym dla każdej klasy. Skupiają się one głównie w obszarze małych wartości `days_left` — ceny w tym obszarze wykazują największą zmienność i są najtrudniejsze do modelowania, co jest zgodne z literaturą (Janssen et al., 2015).



Rysunek 22: Błędy bezwzględne vs. `days_left` — Economy. Największe błędy przy małej liczbie dni do wylotu.




Rysunek 23: Błędy bezwzględne vs. `days_left` — Business. Analogiczny wzorec efektu last-minute.

10.3 Porównanie rozkładów błędów — wszystkie modele

Wykresy pudełkowe błędów bezwzględnych dla wszystkich sześciu modeli umożliwiają wizualne porównanie rozrzutu błędów. LightGBM konsekwentnie wykazuje najniższy medianowy błąd bezwzględny przy najmniejszym IQR — w obu segmentach.



Rysunek 24: Rozkłady błędów bezwzględnych dla wszystkich modeli — Economy (bez outlierów). LightGBM z najniższą medianą.




Rysunek 25: Rozkłady błędów bezwzględnych dla wszystkich modeli — Business (bez outlierów).


11. Wyjaśnialność Modeli (XAI) — SHAP

SHAP (Lundberg & Lee, 2017) przypisuje każdej cesze wkład w predykcję dla konkretnej obserwacji, opierając się na wartościach Shapleya z teorii gier kooperacyjnych. Zastosowano `TreeExplainer` — wydajną implementację dedykowaną modelom drzewiastym.

11.1 Globalny wpływ cech — Summary Plot



Rysunek 26: SHAP summary plot — LightGBM Economy. `days_left` i `duration` dominują.



Rysunek 27: SHAP summary plot — LightGBM Business. Inny rozkład wpływu cech niż w Economy.


Analiza SHAP potwierdza wnioski z literatury i uzasadnia sensowność podziału na segmenty:

- `days_left` jest kluczowym predyktorem w **obu klasach**, ale jego bezwzględny wpływ jest wyraźnie silniejszy w klasie Economy,
- `duration` — dłuższy czas lotu koreluje z wyższą ceną, bardziej regularnie w klasie Business,
- zmienne linii lotniczej mają **większy relatywny wpływ w Business** — przewoźnicy bardziej różnicują ceny w segmencie premium.


Te różnice byłyby zatarte w modelu łącznym, który operuje na jednym zestawie wag dla całej populacji.

11.2 Efekt last-minute — Dependence Plot

Dependence plot dla `days_left` pokazuje wyraźny, nieliniowy wzrost wkładu SHAP dla niskich wartości (lot za 1–10 dni). Model segmentowy precyzyjnie uchwycił ten efekt w każdym segmencie z osobna.



Rysunek 28: SHAP dependence plot `days_left` — Economy. Wyraźny efekt last-minute.



Rysunek 29: SHAP dependence plot `days_left` — Business. Podobny wzorzec, inna skala efektu.

12. Wdrożenie Modelu i Test Predykcyjny

12.1 Test predykcyjny i wnioski

Wyniki testu predykcyjnego potwierdzają poprawność modeli segmentowych i zgodność z oczekiwaniami ekonomicznymi. Poniżej przedstawiono przykładowe predykcje dla obu klas — Economy i Business — wraz z wartościami rzeczywistymi i błędami bezwzględnymi.

Predykcje modeli segmentowych – Economy i Business

Nr	Klasa	Prawdziwa (INR)	Predykcja (INR)	Błąd abs. (INR)
1	Economy	8,043	8,371	328
2	Economy	3,223	4,074	851
3	Economy	2,339	3,839	1,500
4	Economy	3,709	5,198	1,489
5	Economy	2,477	2,376	101
1	Business	53,440	56,956	3,516
2	Business	63,702	53,760	9,942
3	Business	60,978	57,087	3,891
4	Business	58,125	55,671	2,454
5	Business	49,177	51,927	2,750

Rysunek 30: Predykcje modeli segmentowych LightGBM — Economy i Business. Dla klasy Economy błędy bezwzględne mieszczą się w przedziale 101–1500 INR, co stanowi niewielki ułamek typowej ceny biletu. Dla klasy Business odchylenia są proporcjonalnie większe (2 454–9 942 INR), lecz nadal akceptowalne względem znacznie wyższych wartości nominalnych biletów premium.

Obserwacje te potwierdzają trzy kluczowe właściwości modeli:

- **Efekt last-minute:** lot 1 dzień przed wylotem wyceniany wyraźnie wyżej niż 49 dni wcześniej (ten sam rejs, ta sama linia).
- **Efekt klasy podróży:** predykcja dla klasy Business wielokrotnie wyższa niż Economy — każdy segment ma własny model kalibrowany do swojego rozkładu cen.
- **Efekt przesiadek:** loty z wieloma przesiadkami wykazują wyższy błąd bezwzględny — największa zmienność cenowa w tym segmencie.

Porównanie metryk: model łączny vs. segmentowy

Klasa	Model	MAE	RMSE	R ²
Economy	łączny LightGBM	1,230	1,898	0.7262
Economy	Segmentowy LightGBM	1,107	1,751	0.7694
Business	łączny LightGBM	3,457	4,623	0.8215
Business	Segmentowy LightGBM	3,064	4,166	0.8556

Rysunek 31: Porównanie metryk LightGBM: model łączny vs. segmentowy. Model segmentowy redukuje MAE o 10% w klasie Economy (z 1 230 do 1 107 INR) i o 11% w klasie Business (z 3 457 do 3 064 INR). Analogiczne polepszenie widoczne jest dla RMSE oraz R², który wzrasta z 0,7262 do 0,7694 (Economy) i z 0,8215 do 0,8556 (Business).

Zestawienie metryk modelu łącznego i segmentowego dla algorytmu LightGBM jednoznacznie potwierdza przewagę podejścia segmentowego:

13. Podsumowanie i Wnioski

13.1 Model łączny vs. modele segmentowe

Głównym wnioskiem projektu jest wyraźna przewaga **podejścia segmentowego** nad modelem łącznym. Połączony zbiór Economy + Business tworzy heterogeniczną populację, której pojedynczy model nie może optymalnie aproksymować. Osobne modele dla każdej klasy:

- osiągają wyższe R^2 i niższe MAE/RMSE w obu segmentach,
- lepiej uchwytują specyficzne dla każdej klasy zależności (różny wpływ `days_left` i linii lotniczej),
- eliminują problem “kompromisowego” dopasowania.

13.2 Wybór algorytmu — LightGBM jako model finalny

Spośród sześciu testowanych algorytmów **LightGBM** jednoznacznie wyróżnia się jako model finalny z trzech powodów:

1. **Najwyższa dokładność** — najniższe MAE i RMSE, najwyższe R^2 zarówno w modelu łącznym, jak i w obu modelach segmentowych.
2. **Brak przetrenowania** — w przeciwieństwie do Random Forest, który przekracza próg overfittingu w obu klasach ($\text{Train } R^2 - \text{Test } R^2 > 0,05$).
3. **Efektywność** — czas treningu wielokrotnie krótszy niż Random Forest i XGBoost przy porównywalnych lub lepszych wynikach.

13.3 Kluczowe predyktory

Analiza SHAP potwierdza, że `days_left` i `duration` są najważniejszymi predyktorami w obu segmentach, choć z różną siłą oddziaływania. Silny wpływ zmiennych linii lotniczej wskazuje na znaczące zróżnicowanie cenowe między przewoźnikami, nieuchwytne przez modele liniowe.

13.4 Możliwe kierunki dalszych badań

- Głębszy tuning hiperparametrów z wykorzystaniem Optuna / Bayesian Search,
- Integracja zewnętrznych źródeł danych (dni wolne, sezony turystyczne),
- Wdrożenie produkcyjne jako API (Flask / FastAPI) z interfejsem webowym.